

Introduction to WEKA
Preprocess and Classify

PL03



Material

http://hpeixoto.github.io/dc





Weka is a collection of machine learning algorithms for data mining tasks.




WEKA download

https://www.cs.waikato.ac.nz/ml/weka/downloading.html























Weather.arff





Weather.arff





Classification

sometimes called "supervised learning"

Dataset: classified examples



"Model" that classifies new examples

classified example


class

instance:
fixed set of features

discrete ("nominal")
continuous ("numeric")

discrete: "classification" problem
continuous: "regression" problem







BUILD CLASSIFIER

USE J48 TO ANALYZE THE GLASS DATASET

- Open file glass.arff
- Check the available classifiers
- Choose the J48 decision tree learner (trees>J48)
- Run it
- Examine the output
- Look at the correctly classified instances
 - ... and the confusion matrix



BUILD CLASSIFIER

INVESTIGATE J48

- Open the configuration panel
- Check the More information
- Examine the options
- Use an unpruned tree
- Look at leaf sizes
- Set minNumObj to 15 to avoid small leaves
- Visualize tree using right-click menu



BUILD CLASSIFIER

Pruning (decision trees)

is a technique in machine learning that reduces the size of decision trees by removing sections of the tree that provide little power to classify instances. Pruning reduces the complexity of the final classifier, and hence improves predictive accuracy by the reduction of overfitting.



EXERCÍCIO GRUPO

DETERMINAR NECESSIDADE DE COMPONENTES SANGUÍNEOS

No bloco operatório de uma unidade de saúde é de vital importância determinar com a devida antecedência a potencial necessidade de um paciente, que vai ser intervencionado, vir a receber uma ou mais transfusões de componentes sanguíneos (sangue, plasma, etc).

Esta necessidade advém de diversos fatores, tais como:

- Custo unitário de cada fornecimento de componentes sanguíneos;
- Escassez de oferta de componentes sanguíneos;
- Correto tratamento do paciente em caso de necessidade de transfusão;
- Diminuir os desperdícios com o deteriorar de componentes sanguíneos afetos a cirugias que não são usados;
 - entre outros...



EXERCÍCIO

DETERMINAR NECESSIDADE DE COMPONENTES SANGUÍNEOS

Num exercício de brainstorm refletir sobre os principais dados que deveriam estar acessíveis.

nota: Não existe nenhuma limitação técnica nem legal para a recolha de qualquer input. Pelo que todos os dados estarão acessíveis caso sejam considerados.



EXERCISES

FE02



Introduction to WEKA
Preprocess and Classify

PL03